Софийски университет „Св. Кл. Охридски”

Факултет по математика и информатика

Курсов Проект

на тема: „Интелигентни методи за прогнозиране на електроенергийното потребление”

Студент: **Тихомир Тихомиров Галов** Ф.Н. **1MI0600118**

Курс: „IV“, Учебна година: 2024/25

Преподаватели: **проф. Иван Койчев, …,** Консултант(и) (ако има):

==========

Декларация за липса плагиатство:

- Плагиатство е да използваш, идеи, мнение или работа на друг, като претендираш, че са твои. Това е форма на преписване.
- Тази курсова работа е моя, като всички изречения, илюстрации и програми от други хора са изрично цитирани.
- Тази курсова работа или нейна версия не са представени в друг университет или друга учебна институция.
- Разбирам, че ако се установи плагиатство в работата ми ще получа оценка “Слаб”.

24.1.25 г. Подпис на студента:

Съдържание

1 Увод

Прогнозирането на електроенергийното потребление е критично за оптималното управление на енергийни ресурси, планирането на електроразпределителните мрежи и подобряването на ефективността на индустриалните предприятия. В тази курсова работа се изследват няколко различни метода за прогнозиране на потреблението: *Histogram-based Gradient Boosting Regression, Random Forest, Adaptive Boosting Regression, Support Vector Regression* и *Category Boosting Regression*, като се анализира тяхната точност върху два различни набора от данни. Първо, петте ML алгоритъма ще бъдат тествани и от тях ще бъдат избрани трите най-добре представили се. Те ще бъдат тренирани и накрая ще ги съпоставим, за да разберем каква е тяхната успеваемост спрямо класическите изчеслителни методи.

Отделно, целият процес ще го повторим за 2 различни набора данни, за да установим, какво е значението от различното извличане на данни. Целта е да се установи кой от тези методи предоставя най-добра прогнозна способност при различни времеви резолюции и индустриални среди.

2 Подходи за прогнозиране на електроенергийното потребление

В индустриалния сектор прогнозите за електроенергийно потребление се основават на комбинация от традиционни статистически методи и модерни машинно-обучителни алгоритми. Компании като Siemens, General Electric и Schneider Electric интегрират тези технологии в своите интелигентни мрежови решения, за да подобрят точността на прогнозите и ефективността на разпределението.

Сред използваните алгоритми, *Random Forest* и *Gradient Boosting Regressor* представляват ансамблови методи, които използват множество дървета на решения, за да подобрят точността. *Histogram-based Gradient Boosting Regressor* е оптимизирана версия на *Gradient Boosting*, която работи по-ефективно с големи набори от данни. *Adaptive Boosting Regression* се основава на комбинация от слаби обучаващи модели, които постепенно подобряват точността, докато *Category Boosting* е специално разработен за обработка на категорийни данни и сложни нелинейни зависимости. *Support Vector Regression (SVR)* е мощен метод, който използва хиперплоскости за намиране на най-добрите регресионни граници и се справя добре с малки и средно големи набори от данни.

Всеки от тези методи има своите предимства и недостатъци. *Random Forest* предлага стабилност и е устойчив на преобучение, но може да бъде по-бавен при обработка на големи обеми данни. *Gradient Boosting* и неговите варианти често постигат висока точност, но са чувствителни към настройките на параметрите и изискват повече изчислителни ресурси. *Adaptive Boosting* може

да подобри резултатите на базовите модели, но има тенденция да бъде по-податлив на шум в данните. *Category Boosting* е ефективен при обработка на данни с различни видове признаци, но може да бъде по-сложен за настройка. *Support Vector Regression* е подходящ за данни с висока дименсионалност, но може да бъде изчислително интензивен при големи набори от данни.

3 Проектиране

Използва се Jupyter Notebook за разработка на проекта – поставят се различни хипотези, тестват се различни алгоритми, мери се резултатът и се документират експериментите. Най-добрият модел се експортира в .sav файл, който може да се използва от софтуерните инженери, за да създадат потребителски интерфейс и цялостно приложение, което да се използва от крайните потребители.

За целите на анализа се използват 2 различни набора данни:

- Потребление на електричество от компания, работеща в металургическия сектор от Kaggle. Данните са за цялата календарна 2018 година, като наблюденията за потреблението са на 15 минутни интервали - 35038 реда.
- Потребление от компания, занимаваща се с производство на везни и кантари, базирана в Силистра. Данните са събрани от терен за 6 месечен период, наблюденията са на 5 минутни интервали - 53000 реда.

Върху двата набора от данни се прилага stratified split разпределение 80/20 за обучение и тестване. Избраните характеристики са:

- *energy_consumption* в kWh за времевия интервал
- *time* точно време и час на отчитане на метриката
- *day_of_week* ден от седмицата в интервала 0-6 (понеделник - неделя)
- *month* месец от годината 0-11 (януари - декември)
- *is_weekend* булева характеристика, дали е работен ден

Освен това, добавяме и следните колони:

- *lag_1* - Помага за улавяне на краткосрочни тенденции (напр. текущото натоварване на мрежата).
- *lag_1h* - Улавя часовия на работа цикъл (напр. разходът на ток в обедната почивка)
- *lag_1d* - Улавя дневния цикъл (напр. разходът на ток сутрин и вечер)
- *lag_7d* - Открива седмична цикличност (напр. различно потребление през уикендите)

- *lag_1m* - Засича месечни модели (напр. разлика между зимно и лятно потребление)

В крайна сметка получаваме 2 – те групи данни с които ще работим. Това са year_df и half_df, където year_df съдържа данните за 1 година на 15 минутни интервали, а half_df данните за 6 месеца на 5 минутни интервали:

date	energy_consumption	hour	day_of_week	month	is_weekend	lag_1	lag_1h	lag_1d	lag_7d	lag_1m
2018-12-31 23:00:00	3.85	23	0	12	0	3.82	3.42	3.02	3.85	3.42
2018-12-31 23:15:00	3.74	23	0	12	0	3.85	3.24	2.95	3.85	3.28
2018-12-31 23:30:00	3.78	23	0	12	0	3.74	3.67	2.99	3.82	3.38
2018-12-31 23:45:00	3.78	23	0	12	0	3.78	3.82	2.92	3.85	3.31
2018-12-31 00:00:00	3.67	0	0	12	0	3.78	3.85	3.10	3.78	3.35

year_df.tail(5)

date	energy_consumption	hour	day_of_week	month	is_weekend	lag_1	lag_1h	lag_1d	lag_7d	lag_1m
2025-01-15 19:40:00	4.82	19	2	1	0	4.79	6.18	10.81	5.69	3.77
2025-01-15 19:45:00	2.31	19	2	1	0	4.82	5.37	11.46	3.04	4.61
2025-01-15 19:50:00	3.50	19	2	1	0	2.31	5.13	10.47	3.04	4.33
2025-01-15 19:55:00	4.33	19	2	1	0	3.50	4.38	10.30	3.03	4.31
2025-01-15 20:00:00	4.41	20	2	1	0	4.33	6.95	8.87	4.98	4.27

half_df.tail(5)

Както може да забележим, след премахване на нулевите стойности, данните ни са съответно 32160 и 43479. След разделянето на данните за трениране/тестване получаваме крайните числа от:

	Тренировъчни	Тестови
Годишни	25728	6432
6 месечни	34783	8696

4 Реализация, тестване и експерименти

4.1 Използвани технологии, платформи и библиотеки

Експерименталният процес включва следните стъпки:

- Предварителна обработка на данните – почистване, трансформиране и нормализиране (извършена в стъпка 3)
- Разделяне на данните на 2 части - обучаващи и тестови (извършена в стъпка 3)

- Обучение на моделите – настройване на параметри чрез GridSearch за оптимална производителност
- Тестване на моделите върху тестовия набор от данни
- Запазване на обучените модели като файлове за бъдещи корекции
- Оценка на моделите – сравнение чрез метриките Mean Squared Error (MSE), Mean Absolute Error (MAE), Root Mean Square Error (RMSE), Coefficient of Determination (R^2).
- Анализ на резултатите – визуализация на предсказаните спрямо реалните стойности.

Помощни функции

Започваме с дефиниране на някои функции, които ще бъдат често използвани. Ще дефинираме помощна функция **fit_model**, която ще извърши grid search върху нашите модели и ще върне речник със следната информация:

- **model** - съдържа името на алгоритъма
- **number_features_training** - съдържа броя на характеристиките в текущия модел
- **best_estimator** - съдържа най-добрия модел от проведения grid search
- **best_params** - съдържа най-добрите хиперпараметри, които дават най-високите метрики (в нашия случай “точност”)
- **best_score** - съдържа най-високият резултат за точност
- **time_sec** - съдържа времето за изпълнение на grid_search

Освен това, имаме и няколко функции, които се занимават с форматирането на входните данни, както и с подравняването за тестовете на двата набора от данни. Това са:

- set_lags_15min(df) – за генерирането на lags за данните с 15 минутни интервали
- set_lags_5min(df) – за генерирането на lags за данните с 5 минутни интервали
- set_time(df) – За отбелязване на булеви стойности, дали денят е почивен или работен

```
def fit_model(model, parameters_grid, k_fold, X_train, y_train):
    t0 = time()
    grid_search = GridSearchCV(model, parameters_grid, n_jobs=1, scoring='r2',
cv=k_fold)
    grid_search.fit(X_train, y_train)
```

```python
    t1 = time() - t0

    return {"model": model.__class__.__name__,
            "number_of_observations_training": X_train.shape[0],
            "number_features_training": X_train.shape[1],
            "best_estimator": grid_search.best_estimator_,
            "best_params": grid_search.best_params_,
            "best_score": grid_search.best_score_,
            "time_sec": t1}

def set_lags_15min(df):
    df['lag_1'] = df['energy_consumption'].shift(1)
    df['lag_1h'] = df['energy_consumption'].shift(4)
    df['lag_1d'] = df['energy_consumption'].shift(96)
    df['lag_7d'] = df['energy_consumption'].shift(672)
    df['lag_1m'] = df['energy_consumption'].shift(2880)  # 30 days * 24 hours * 4 intervals/hr = 2880

def set_lags_5min(df):
    df['lag_1'] = df['energy_consumption'].shift(1)
    df['lag_1h'] = df['energy_consumption'].shift(12)
    df['lag_1d'] = df['energy_consumption'].shift(288)
    df['lag_7d'] = df['energy_consumption'].shift(2016)
    df['lag_1m'] = df['energy_consumption'].shift(8640) # 30 days * 24 hours * 12 intervals/hr = 8640

def set_time(df):
    df['hour'] = df.index.hour
    df['day_of_week'] = df.index.dayofweek
    df['month'] = df.index.month

    if 'WeekStatus' in df.columns:
        df['is_weekend'] = df['WeekStatus'].map({'Weekday': 0, 'Weekend': 1})
    else:
        df['is_weekend'] = df.index.dayofweek.isin([5, 6]).astype(int)
```

Зареждане на данните

```
[22]: half_df.describe()
```

[22]:

	energy_consumption	hour	day_of_week	month	is_weekend	lag_1	lag_1h	lag_1d	lag_7d	lag_1m
count	43479.000000	43479.000000	43479.000000	43479.000000	43479.000000	43479.000000	43479.000000	43479.000000	43479.000000	43479.000000
mean	13.838550	11.500034	3.008855	9.309161	0.291359	13.838623	13.838433	13.786793	13.630228	14.106281
std	19.259735	6.940150	2.007298	3.018650	0.454394	19.259706	19.259793	19.194485	18.952430	19.033400
min	-3.740000	0.000000	0.000000	1.000000	0.000000	-3.740000	-3.740000	-3.740000	-3.740000	-0.020000
25%	2.670000	5.000000	1.000000	9.000000	0.000000	2.670000	2.670000	2.670000	2.650000	2.650000
50%	4.210000	11.000000	3.000000	10.000000	0.000000	4.210000	4.210000	4.170000	4.060000	3.860000
75%	13.110000	18.000000	5.000000	11.000000	1.000000	13.110000	13.110000	13.225000	13.970000	20.815000
max	110.600000	23.000000	6.000000	12.000000	1.000000	110.600000	110.600000	110.600000	110.600000	110.600000

```
[21]: year_df.describe()
```

[21]:

	energy_consumption	hour	day_of_week	month	is_weekend	lag_1	lag_1h	lag_1d	lag_7d	lag_1m
count	32160.000000	32160.000000	32160.000000	32160.000000	32160.000000	32160.000000	32160.000000	32160.000000	32160.000000	32160.000000
mean	26.105095	11.500000	3.005970	7.020896	0.286567	26.108028	26.115840	26.257272	26.810880	28.016340
std	32.293016	6.922294	2.000022	3.158007	0.452165	32.295261	32.300208	32.370944	32.663332	33.867196
min	0.000000	0.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	3.170000	5.750000	1.000000	4.000000	0.000000	3.170000	3.170000	3.170000	3.170000	3.170000
50%	4.180000	11.500000	3.000000	7.000000	0.000000	4.180000	4.180000	4.180000	4.320000	4.610000
75%	49.977500	17.250000	5.000000	10.000000	1.000000	50.000000	50.000000	50.290000	50.760000	51.840000
max	157.180000	23.000000	6.000000	12.000000	1.000000	157.180000	157.180000	157.180000	157.180000	157.180000

След като сме ги разделили, добавили колоните и форматирали, имаме една последна стъпка, която е да отделим характеристиките от етикетите. Така в крайна сметка имаме 8 променливи:

```
def split(df, X, y):
    split_index = int(len(df) * 0.8)
    X_train, X_test = X.iloc[:split_index], X.iloc[split_index:]
    y_train, y_test = y.iloc[:split_index], y.iloc[split_index:]

    return X_train, X_test, y_train, y_test

year_feats_train, year_feats_test, year_labels_train, year_labels_test =
split(year_df, year_feats, year_labels)
half_feats_train, half_feats_test, half_labels_train, half_labels_test =
split(half_df, half_feats, half_labels)
```

Метрики за измерване на производителността на модела

Въпреки че съществуват различни метрики за оценка на моделите (като MSE, RMSE, MAE и др.), в нашия анализ ще използваме **R^2 (коефициент на детерминация)** като основна метрика за измерване на производителността. R^2 ще ни помогне да оценим как добре моделът улавя вариациите в консумацията на електроенергия. Освен това ще анализираме **графики на остатъчните грешки (residual errors)**, за да оценим разпределението на грешките в предсказанията и ще сравним различните модели (Gradient Boosting, Random Forest и т.н) спрямо тяхната ефективност и време за обучение.

4.2 Реализация

Сравнение на ML алгоритмите за данните с 5 минутен интервал

Ще тренираме и тестваме моделите на двата различни набора от данни, поради разликата в методите им на отчитане на енергия. Това може да означава, че по - общият модел (15 минутен интервал) е по - ефективен, тъй като информацията в него е по – консолидирана, т.е с намалена дисперсия. Това е специфика на сектора, в който сравняваме тези модели, защото електропотреблението може да варира доста в рамките на минути, поради различните режими на работа на електроуредите и поведението на хората. Например използването на микровълнова фурна в 12:00 часа на обяд, би се отразила като голяма

флуктоация, но е само за няколко минути и бихме могли да я изключим в общата “картина” за индустриално потребление.

Избиране на алгоритми

Използвайки cross validation с 5 фолда върху обучаващия набор с ‘r2’ като метрика, ще изберем три от най-добрите алгоритъма. Ще ги стартираме с техните настройки по подразбиране. Петте кандидата са:

- Histogram based Gradient Boosting Regression
- AdaBoost Regression
- Random Forrest
- Support Vector Regression
- Category Boosting Regression

```
k_fold = KFold(n_splits = 5)

results = []
names = []
scoring = 'r2'
algorithms = []
algorithms.append(("HGBR", HistGradientBoostingRegressor(verbose=0)))
algorithms.append(("AdaBoost", AdaBoostRegressor()))
algorithms.append(("RandomForest", RandomForestRegressor(verbose=0)))
algorithms.append(("SVR", SVR(verbose=0)))
algorithms.append(("CatBoostRegressor", CatBoostRegressor(verbose=0)))
for name, algorithm in algorithms:
    t0=time()
    cv_results = cross_val_score(algorithm, half_feats_train, half_labels_train,
cv= k_fold, scoring = scoring)
    t1 = time() - t0
    results.append(cv_results)
    names.append(name)
    print("{0}: mean r2 {1:.3%} - standard deviation {2:.4} - time
{3:n}".format(name, cv_results.mean(), cv_results.std(), t1))
```

```
HGBR: mean r2 90.850% - standard deviation 0.00806 - time 0.825964
AdaBoost: mean r2 87.538% - standard deviation 0.01588 - time 3.13016
RandomForest: mean r2 90.350% - standard deviation 0.007167 - time 60.32
SVR: mean r2 90.239% - standard deviation 0.007325 - time 72.3117
CatBoostRegressor: mean r2 90.513% - standard deviation 0.008161 - time
5.92087
```

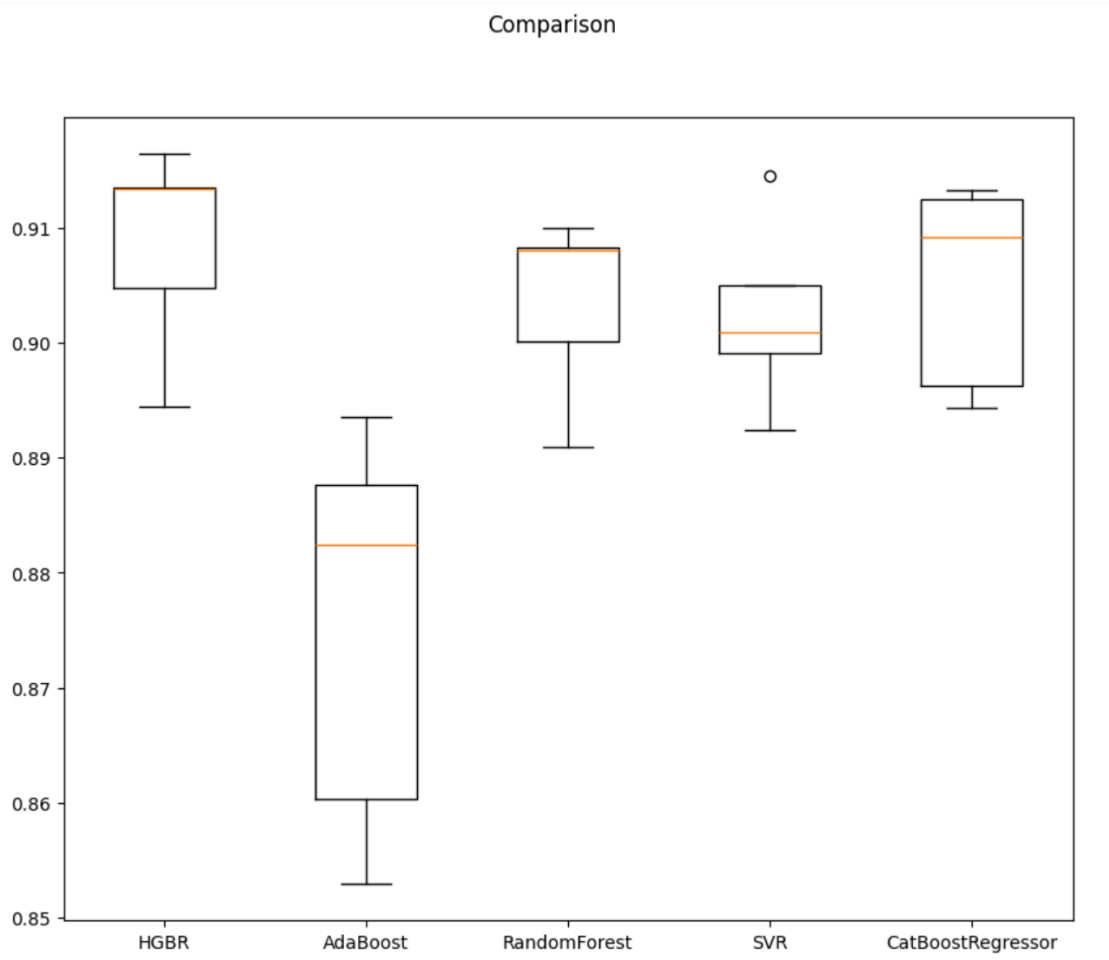

Както се вижта ясно от графиката, трите най - добри алгоритъма са Histogram Gradient Boosting Regression, Category Boosting Regression и Random Forest. Въпреки че Random Forest е значително по - бавен, той по - добър от AdaBoost и SVR, поради което се спираме на него като 3ти алгоритъм за по - подробен анализ.

Random Forest

```
model = RandomForestRegressor()
parameters_grid = [{
    'n_estimators': [100, 200, 300],
    'max_depth': [1, 5, 10],
}]
model_fit = fit_model(model, parameters_grid, k_fold, half_feats_train,
half_labels_train)
```

```
{'model': 'RandomForestRegressor',
 'number_of_observations_training': 34783,
 'number_features_training': 9,
 'best_estimator': RandomForestRegressor(max_depth=5),
 'best_params': {'max_depth': 5, 'n_estimators': 100},
 'best_score': 0.9104016599630558,
 'time_sec': 282.4987325668335}
```

```
R2 score for the selected model is: 91.029%
```

Оценката не е значително по - висока спрямо първоначалния подбор. Следващата стъпка е да тестваме модела спрямо тестовите данни.

```
Test score 92.403%
```

Тестовата оценка е добра, така че запазваме данните за модела, за да избегнем генерирането му наново при следващи тестове.

Нека покажем разликата в резултатите между тестовите прогнози и реалните стойности

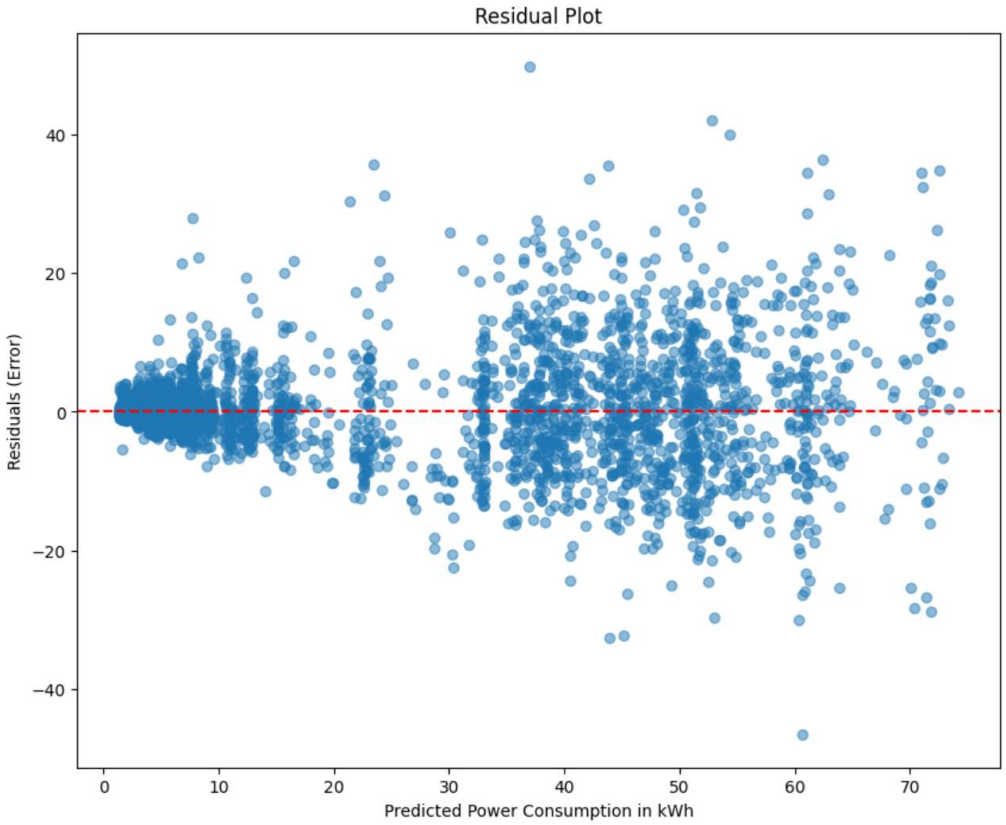


```
Regression Report:
Mean Absolute Error (MAE): 2.1928
Root Mean Square Error (RMSE): 21.9146
R² Score: 0.9240
```

Category Boosting Regression

```
model = CatBoostRegressor(verbose=0)
parameters_grid = [{
    "iterations": [200, 500, 1000],  # Number of boosting iterations
    "learning_rate": [0.01, 0.05, 0.1],  # Learning rate (smaller = better
generalization)
    "depth": [4, 6, 8, 10],  # Tree depth (controls model complexity)
    "l2_leaf_reg": [1, 3, 5, 7],  # L2 regularization (prevents overfitting)
}]
```

```
model_fit = fit_model(model, parameters_grid, k_fold, half_feats_train,
half_labels_train)
```

```
{'model': 'CatBoostRegressor',
 'number_of_observations_training': 34783,
 'number_features_training': 9,
 'best_estimator': <catboost.core.CatBoostRegressor at
0x7dda43902ae0>,
 'best_params': {'depth': 6,
  'iterations': 1000,
  'l2_leaf_reg': 7,
  'learning_rate': 0.01},
 'best_score': 0.9117558460590299,
 'time_sec': 1038.05260014534}
```

```
R2 score for the selected model is: 91.176%
```

Оценката не е значително по - висока спрямо първоначалния подбор. Следващата стъпка е да тестваме модела спрямо тестовите данни.

```
Test score 92.046%
```

Забелязваме, че тестовата оценка е по - ниска от тази на Random Forest, въпреки по - добрия резултат на Category Boosting Regression при останалите сравнанения. Това означва, че Random Forest се справя значително по - добре с обобщаването на данните.

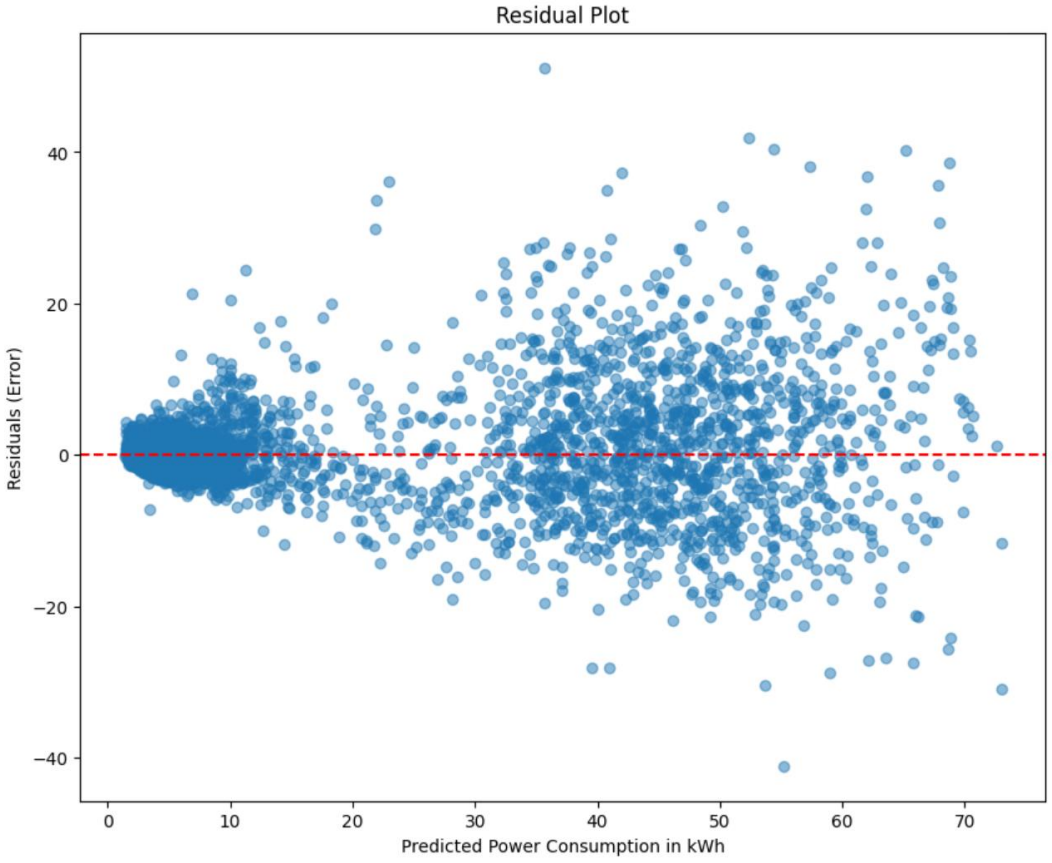

```
Regression Report:
Mean Absolute Error (MAE): 2.4046
Root Mean Square Error (RMSE): 22.9440
R² Score: 0.9205
```

Histogram Gradient Boosting Regression

Използваме **HistGradientBoostingRegressor (HGBR)** вместо **GradientBoostingRegressor (GBR)**, защото HGBR е оптимизиран за големи набори от данни и е значително по-бърз. HGBR използва дискретизация на данните в хистограми, което намалява сложността и паметната консумация, докато GBR изгражда дървета, които обработват всяка стойност поотделно, което е по-бавно. Предимствата на HGBR включват по-добра мащабируемост, вградена поддръжка за ранно спиране и по-добра работа с числови данни. Въпреки това, недостатъкът на HGBR е, че не поддържа категориални променливи директно (за разлика от CatBoost) и понякога може да загуби детайлност при по-малки набори от данни. От друга страна, GBR е по-гъвкав, особено за по-малки или по-шумни данни, но страда от по-бавно обучение и по-висока паметна консумация. Конкретно в нашия случай, скоростта при трениране на моделите е основната разлика, заради която ще се спрем на HGBR.

```
model = HistGradientBoostingRegressor(verbose=0)
parameters_grid = [{
    "learning_rate": [0.01, 0.05, 0.1],  # Step size at each iteration
    "max_iter": [200, 500, 1000],  # Number of boosting iterations
    "max_depth": [3, 5, 7, 10],  # Depth of each tree
    "max_leaf_nodes": [10, 20, 31, 50],  # Max number of leaf nodes per tree
    "early_stopping": [True],  # Stop training if validation score stops improving
}]
model_fit = fit_model(model, parameters_grid, k_fold, half_feats_train,
half_labels_train)
```

```
{'model': 'HistGradientBoostingRegressor',
 'number_of_observations_training': 34783,
 'number_features_training': 9,
 'best_estimator':
HistGradientBoostingRegressor(early_stopping=True,
learning_rate=0.05, max_depth=3, max_iter=1000, max_leaf_nodes=10),
 'best_params': {'early_stopping': True,
  'learning_rate': 0.05,
  'max_depth': 3,
  'max_iter': 1000,
  'max_leaf_nodes': 10},
 'best_score': 0.9119880394850179,
 'time_sec': 237.53853964805603}

R2 score for the selected model is: 91.199%
```

Оценката не е значително по - висока спрямо първоначалния подбор. Осезаема обаче е разликата във времето за трениране на този модел. Тук имаме само 237 секунди, за разлика от 1038 секунди при **CatBoost**, където наблюдаваме почти идентичен резултат.

```
Test score 92.224%
```

Тук оценката е малко по - ниска, спрямо тази на **Random Forest**, въпреки че и двете имат сходно време за трениране - **HGBR** е по - бърз с **около 45 секунди.**

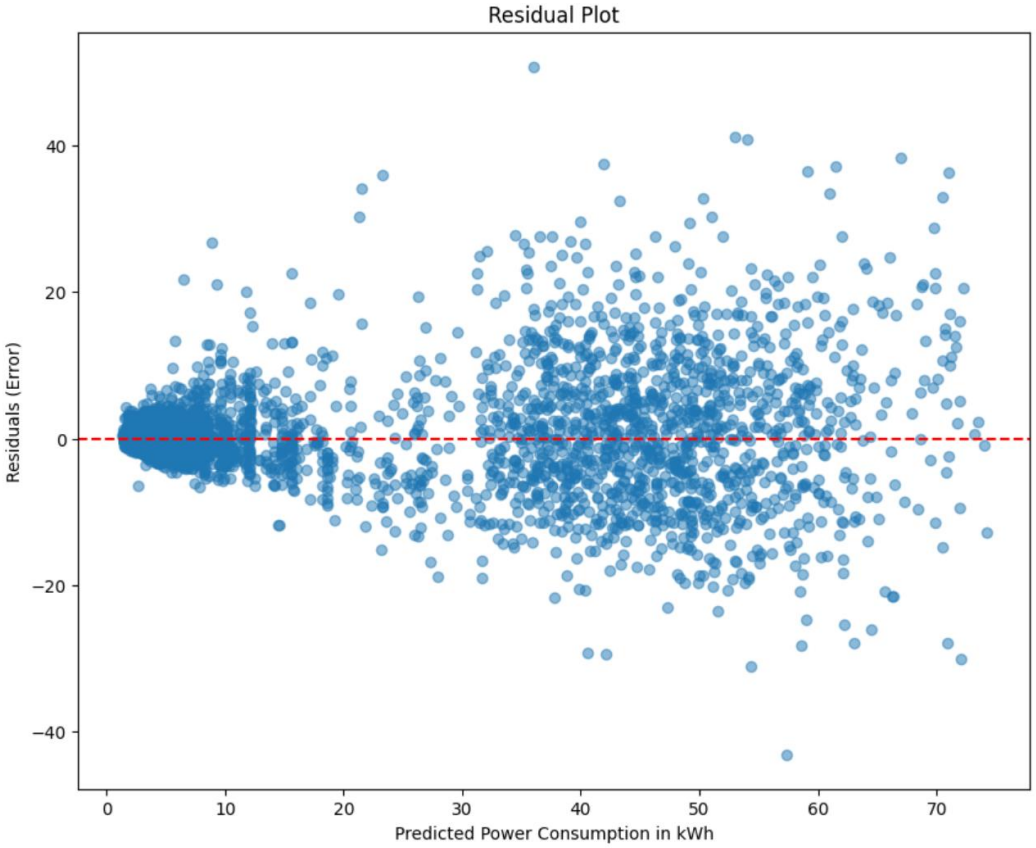


```
Regression Report:
Mean Absolute Error (MAE): 2.2943
Root Mean Square Error (RMSE): 22.4319
R² Score: 0.9222
```

Сравнение на ML алгоритмите за данните с 15 минутен интервал

Нека направим същите сравнения и на втората група от данни. Това ще ни даде доста по - добро разбиране, как работят тези модели и какъв подбор на данни е нужно да направим за оптимални резултати.

Избор на алгоритми

```
HGBR: mean r2 88.878% - standard deviation 0.02141 - time 0.868416
AdaBoost: mean r2 81.995% - standard deviation 0.03007 - time 2.65092
RandomForest: mean r2 88.191% - standard deviation 0.02228 - time 37.6435
SVR: mean r2 85.252% - standard deviation 0.01347 - time 38.6259
```

CatBoostRegressor: mean r2 88.283% - standard deviation 0.02581 - time 5.25396

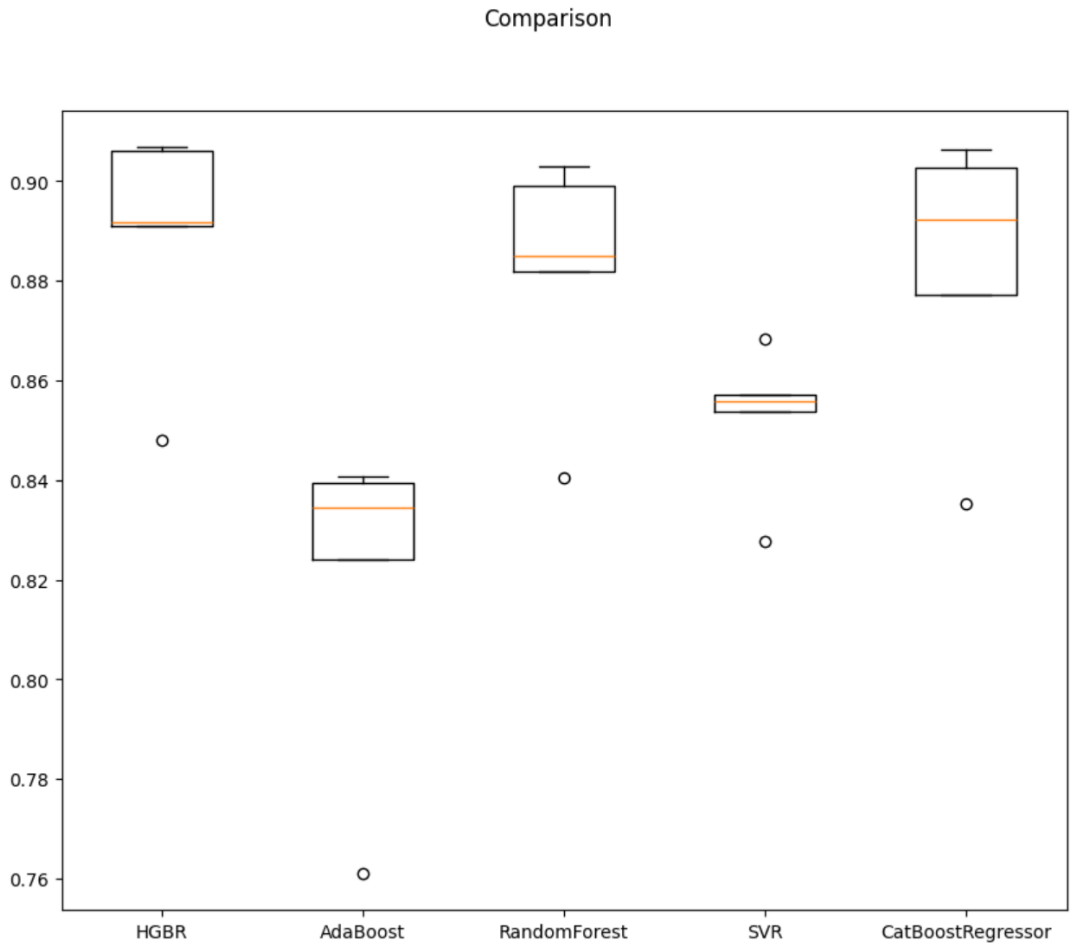

При по-широкия диапазон от информация, виждаме запазване на последователността от алгоритми, като основната разлика е че точността им е с около 2 пункта по-ниска.

За същите три алгоритъма ще направим същите тестове, със същите параметри. Тъй като са идентични процеси, в следващите страници ще покажем само резултатите.

Random Forest

```
{'model': 'RandomForestRegressor',
 'number_of_observations_training': 25728,
 'number_features_training': 9,
 'best_estimator': RandomForestRegressor(max_depth=10,
n_estimators=300),
 'best_params': {'max_depth': 10, 'n_estimators': 300},
 'best_score': 0.8852067633262906,
 'time_sec': 188.7670624256134}

R2 score for the selected model is: 88.521%
```

Оценката не е значително по - висока спрямо първоначалния подбор. Следващата стъпка е да тестваме модела спрямо тестовите данни.

```
Test score 91.186%
```

Тук виждаме по-лоша тестова оценка спрямо тренировърната информация и спрямо същия алгоритъм за 5 минутни интервали. Въпреки това, тя е по-добра спрямо резултата на тренировъчната информация.

Нека покажем разликата в резултатите между тестовите прогнози и реалните стойности.

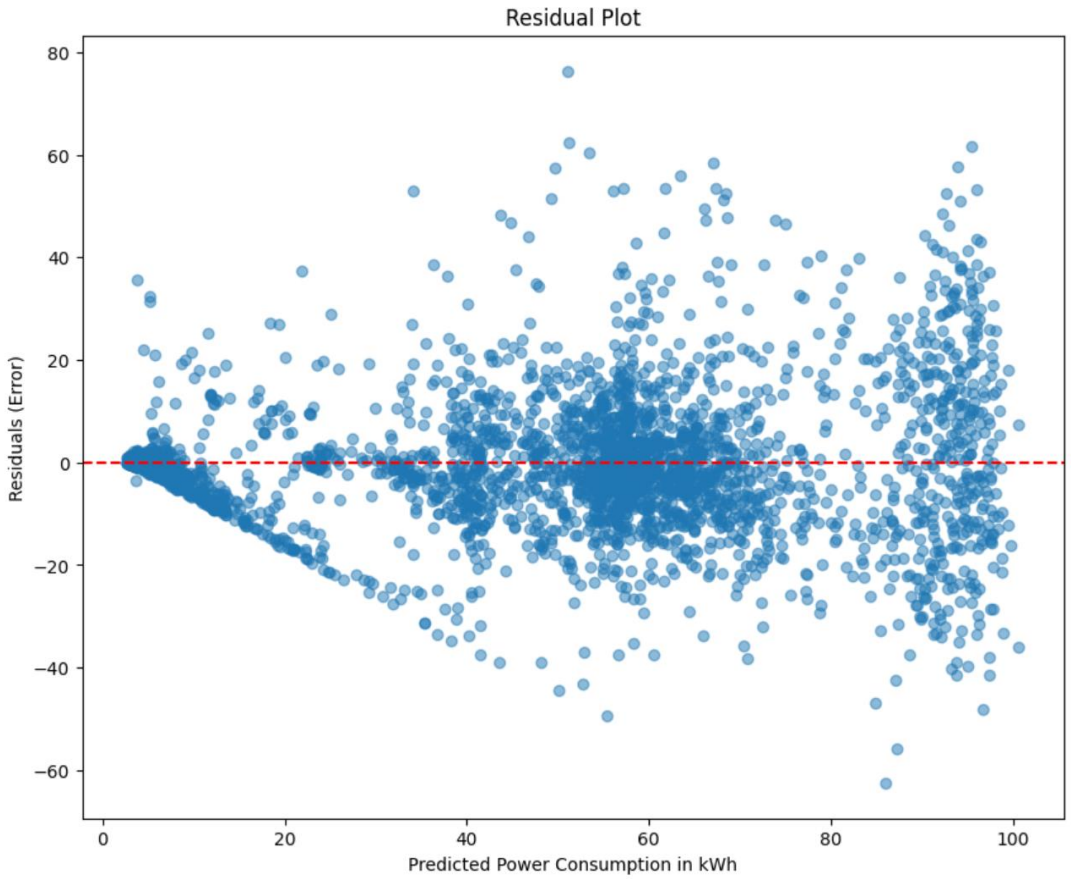


```
Regression Report:
Mean Absolute Error (MAE): 4.5163
Root Mean Square Error (RMSE): 87.1134
R² Score: 0.9119
```

Category Boosting Regression

```
{'model': 'CatBoostRegressor',
 'number_of_observations_training': 25728,
 'number_features_training': 9,
 'best_estimator': <catboost.core.CatBoostRegressor at 0x7dda4fbe8410>,
 'best_params': {'depth': 6,
  'iterations': 500,
  'l2_leaf_reg': 5,
```

```
  'learning_rate': 0.05},
 'best_score': 0.8894011386707568,
 'time_sec': 984.630047082901}
```

```
R2 score for the selected model is: 88.940%
```

```
Test score 91.328%
```

Забелязваме, че тестовата оценка е по - висока от тази на Random Forest, въпреки по - добрия резултат на Category Boosting Regression при останалите сравнанения. Това означва, че CBR се справя значително по - добре с обобщаването на данните, особено в контекста на по - малко информация.

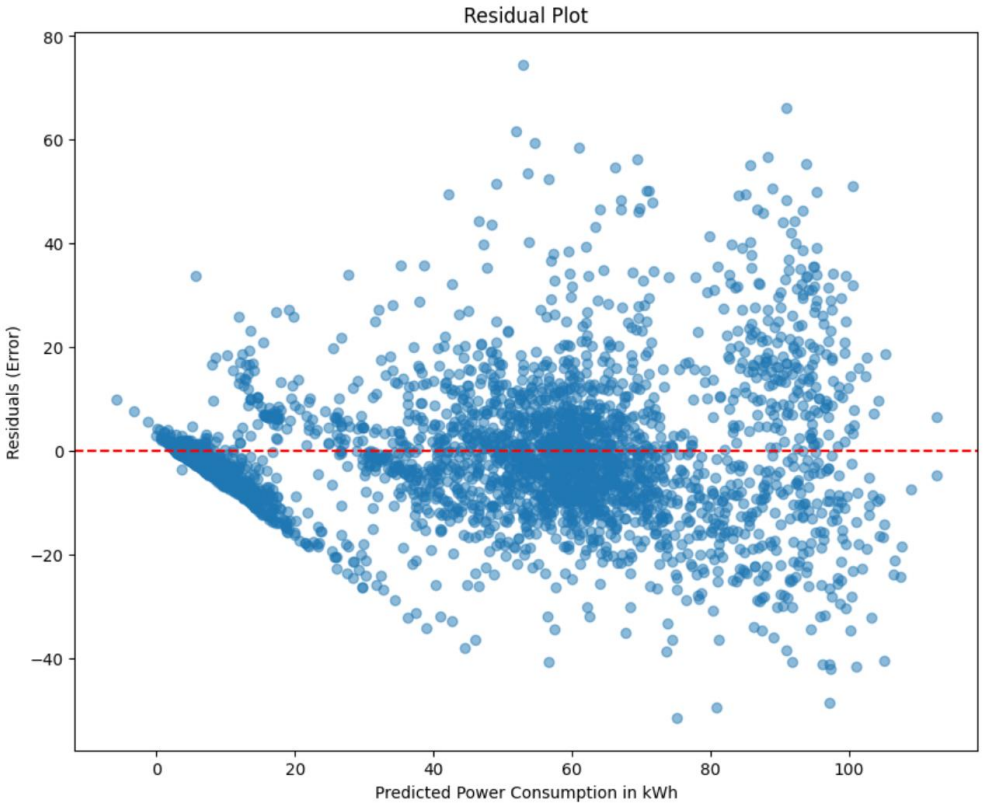


```
Regression Report:
Mean Absolute Error (MAE): 4.9202
Root Mean Square Error (RMSE): 85.7071
R² Score: 0.9133
```

Histogram Gragient Boosting Regression

```
{'model': 'HistGradientBoostingRegressor',
 'number_of_observations_training': 25728,
 'number_features_training': 9,
 'best_estimator':
HistGradientBoostingRegressor(early_stopping=True, max_depth=10,
max_iter=500, max_leaf_nodes=10),
 'best_params': {'early_stopping': True,
  'learning_rate': 0.1,
```

```
  'max_depth': 10,
  'max_iter': 500,
  'max_leaf_nodes': 10},
 'best_score': 0.890122775974881,
 'time_sec': 293.044228553772}
```

```
R2 score for the selected model is: 89.012%
```

Оценката не е значително по - висока спрямо първоначалния подбор. **HGBR** обаче запазва първото място, като резултат.

```
Test score 91.327%
```

Тук оценката е малко по - ниска, спрямо тази на **CBR**, въпреки че и двете имат сходно време за трениране - **HGBR** е по - бърз с **~690 секунди.**

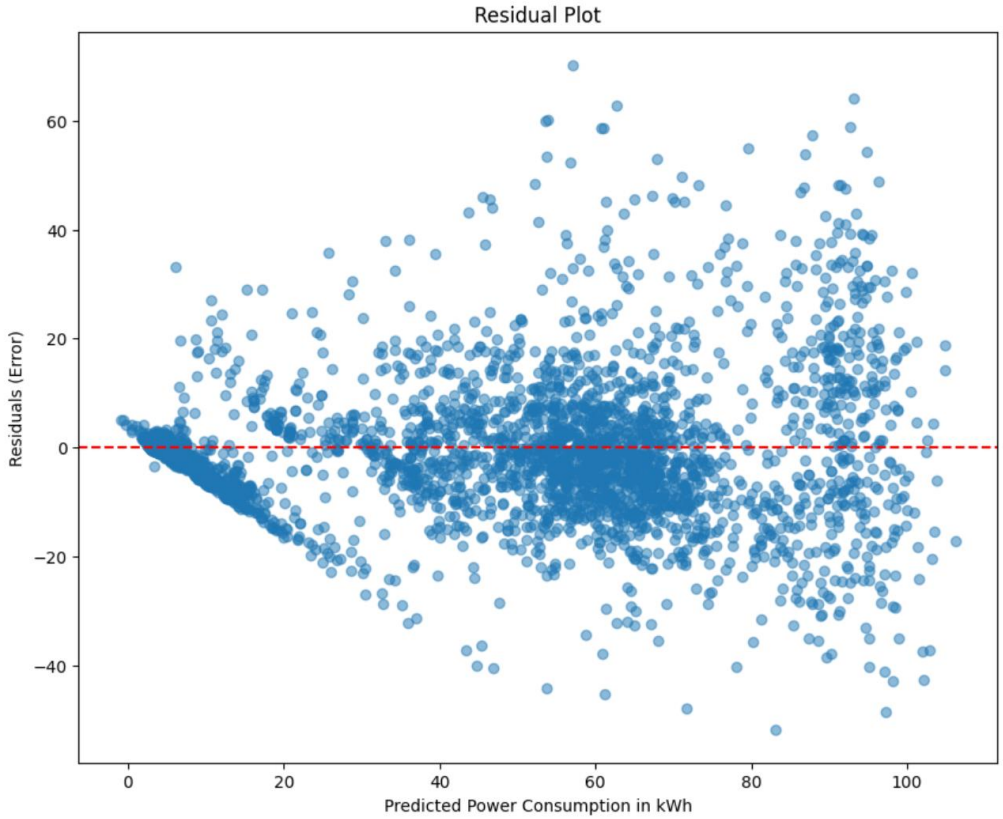


```
Regression Report:
Mean Absolute Error (MAE): 4.6863
Root Mean Square Error (RMSE): 85.7202
R² Score: 0.9133
```

4.3 Анализ на резултатите

След като генерирахме шестте модела е време да разгледаме в детайли финалните резултати. Ще започнем с директно сравнение на моделите по постигната точност на данни за трениране и тестване.

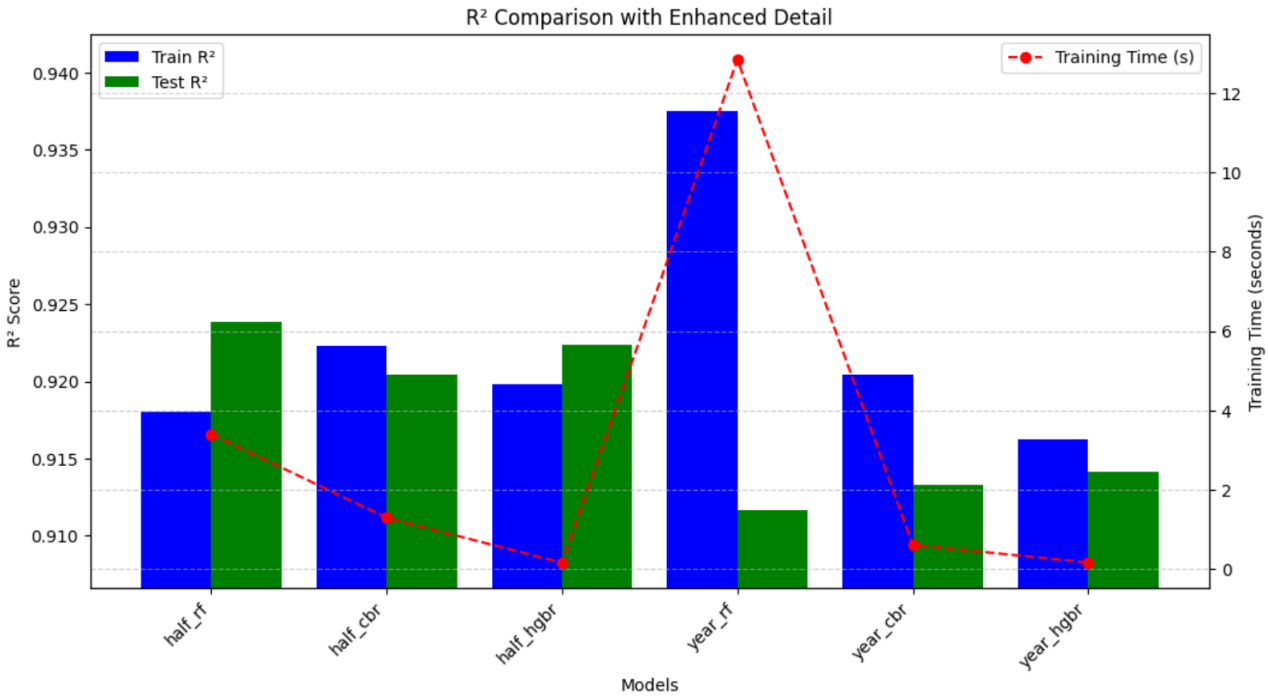

Тази графика демонстрира сравнението между **обучителните и тестовите R^2 стойности**, както и времето за обучение на различните модели.

Разлика между половин-годишните и едногодишните данни

- **half модели (6 месеца, 5-минутни интервали):**
  - Данните са с по-висока резолюция, което предполага повече информация за краткосрочни колебания.
  - Тези модели имат по-ниски времена за обучение, но R^2 стойностите са относително сходни (около 91.7-92.3%).
  - Тестовите R^2 стойности са почти равни на тренировъчните, което означава добро обобщение и минимален риск от пренасищане (overfitting).
- **year модели (1 година, 15-минутни интервали):**
  - По-дългосрочен набор данни с по-ниска времева резолюция, което може да доведе до по-груби прогнози.

- year_rf (Random Forest) показва най-висока стойност на R^2 (94%) за тренировъчни данни, но времето за обучение значително се увеличава.

- и при трите алгоритъма наблюдаваме значително по висок резултат на тренировъчните данни, спрямо тестовите**.**

Важността на обучителното време

- **half_hgbr и year_hgbr (HistGradientBoostingRegressor):**
  - Те показват добър баланс между време за обучение и точност.
  - Особено подходящи за приложения, където скоростта е критична.
- **half_rf (Random Forest):**
  - Висок R^2, но значително време за обучение, което може да е проблематично за реалновремеви системи.

Алгоритми и подходящи сценарии

- **CatBoost (half_cbr, year_cbr):**
  - Изглежда стабилно представяне, но е с малко по-ниски R^2 стойности в тестовия набор, което предполага леко подобобщение на данните.
- **Random Forest (half_rf, year_rf):**
  - По-висока точност, но с компромис във времето за обучение. Подходящ за ситуации, където производителността не е критична.
- **HistGradientBoostingRegressor (half_hgbr, year_hgbr):**
  - Впечатляващ компромис между скорост и точност, идеален за реалновремеви системи за управление на енергия.

- **За краткосрочни прогнози (напр. за контрол на енергийни системи):**
  - **half_hgbr** или **half_cbr** са добър избор, поради ниско време за обучение и висока точност.
- **Общи препоръки:**
  - Моделите на **HistGradientBoostingRegressor** предоставят добър компромис между време за обучение и R^2, което ги прави особено подходящи за повечето приложения.

Основни разлики между тестовите данни в различните набори от данни

След анализа на самите модели, нека обърнем внимание на разликите в имплементацията модела между двата набори от данни. За целта ще вземем дистрибуцията при *HGBR* за двата вида данни.

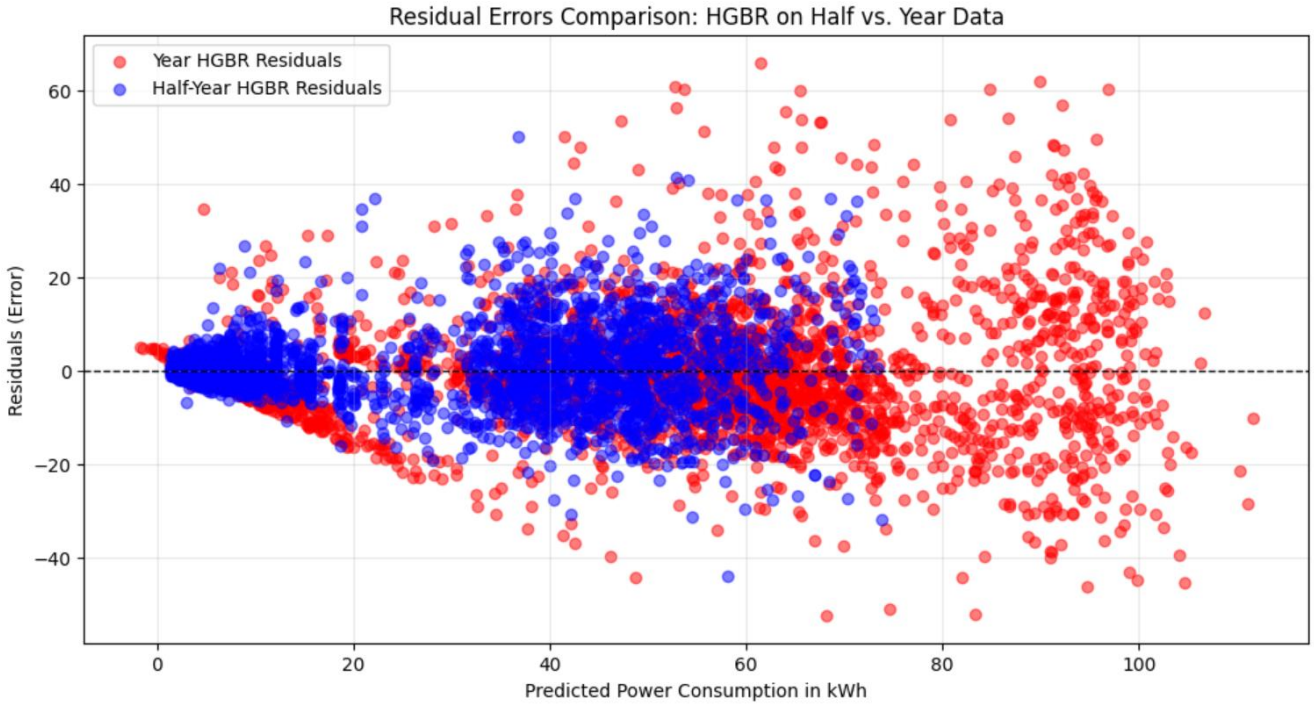

Както можем да видим, отклонението на полугодишните данни е доста по-концентрирано около центъра и съответно поради естеството на данните достига по-малки стойности. Забелязваме обаче и една интересна тенденция при годишните данни - грешките се увеличават линейно от 0 до 45 kWh, което подсказва за доста обобщени първоначални данни (underfitting).

5 Заключение

Използвахме различни алгоритми за машинно обучение и методи за намаляване на размерността на данните. Въпреки че всички алгоритми се справиха сходно, смятам че *HGBR* за данни с 5 минутни интервали се справи най-добре. Комбинацията от висока точност, изключително малко време за трениране и ниската дисперсия на данните би била перфектна за имплементация в **high availability** системи с много клиенти.

Използването на 2 различни вида данни показа доста различия в работата на различните алгоритми. Въпреки притесненията налието на данни на всеки 5 минути не доведе до **overfitting**, това обаче може да се промени ако вземем по - извадка данни с по малки стойности. Смятам, че ако се проведе същият експеримент за електропотребление на домакинства, вместо на индустриални предприятия, има потенциал за промяна в избора. Това би се дължало на факта, че в домакинство е много лесно да постигнеш флуктоация в в потреблението за кратък интервал. Това би довело до голяма дисперсия на данните и потенциално, текущите алгоритми не биха се справили токкова добре.

За бъдещи подобрения, би било интересно да се добавят още параметри към първоначалните данни. Наличието на данни за метеорологичните условия, би

добавило още информация за разходите за отопление/охлаждане. Също така и параметри, специфични за работния процес в конкретното индустриално предприятие имат потенциал значително да повишат точността на моделите.

6 Използвана литература

1. Energy Consumption Prediction by using Machine Learning Case Study Malaysia (https://www.researchgate.net/publication/347479213_Energy_Consumption_Prediction_by_using_Machine_Learning_for_Smart_Building_Case_Study_in_Malaysia)
2. Kaggle (https://www.kaggle.com/datasets/csafrit2/steel-industry-energy-consumption)
3. HistGradientBoostingRegressor (https://scikit-learn.org/1.5/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html)
4. RandomForestRegressor (https://scikit-learn.org/1.5/modules/generated/sklearn.ensemble.RandomForestRegressor.html)
5. AdaBoostRegressor (https://scikit-learn.org/1.5/modules/generated/sklearn.ensemble.AdaBoostRegressor.html)
6. CatBoostRegressor (https://catboost.ai/docs/en/concepts/python-reference_catboostregressor)
7. SVR (https://scikit-learn.org/1.5/modules/generated/sklearn.svm.SVR.html)
8. KMeans (https://scikit-learn.org/1.5/modules/generated/sklearn.cluster.KMeans.html)
9. GridSearchCV (https://scikit-learn.org/1.5/modules/generated/sklearn.model_selection.GridSearchCV.html)